



# Image Colorization Using Deep Learning

Ivan Ristić IN31-2022  
Isidor Ivanov IN50-2022  
Nemanja Radić IN34-2022  
Uroš Ogrizović IN12-2022



# Zašto kolorizovati slike?

- Restauracija starih crno-belih slika
- Obogatiti istorijske arhive
- Poboljšanje medicinskih fotografija
- Kreativne i umetničke aplikacije



# Pregled projekta

- **Cilj**
  - Napraviti neuronsku mrežu koja uzima crno-bele slike i predviđa njihove obojene verzije
- **Alati**
  - Python, TensorFlow/Keras, Matplotlib, Pandas, NumPy



# Priprema podataka

- **DataSet:** Slike sa

*<https://www.kaggle.com/datasets/puneet6060/intel-image-classification/data>*

- **Koraci**

- Učitavanje putanja slika iz subfoldera
- Promena dimenzija slika na  $128 \times 128$  piksela radi lakše obrade
- Konvertovanje slika u sive tonove za unos modela
- Normalizovanje vrednosti piksela na  $[0, 1]$  za treniranje neuronske mreže



# Arhitektura modela

- **Encoder-Decoder:** Jednostavna struktura autoenkodera
- **CNN:** Duboka konvoluciona neuronska mreža
- **U-Net:** Napredna arhitektura sa preskočnim vezama za bolje zadržavanje detalja



# Encoder-Decoder Model

- **Struktura**
  - Model je zasnovan na jednostavnoj enkoder-dekoder arhitekturi
  - Enkoder kompresuje ulaznu sliku u sivim tonovima u sažetu reprezentaciju karakteristika pomoću konvolucionih slojeva.
  - Dekoder koristi te karakteristike da rekonstruiše izlaznu sliku u boji (RGB formatu).
- **Korišćeni slojevi**
  - Conv2D, BatchNormalization, MaxPooling2D, Dropout, UpSampling2D
- **Prednosti**
  - Lak za implementaciju i obuku
  - Dobar za učenje osnovnih obrazaca bojenja
- **Ograničenja**
  - Može doći do gubitka finih detalja i stvaranja замуćenih rezultata



# CNN Model

- **Struktura**
  - Duboka konvoluciona neuronska mreža
  - Višestruki konvolucioni blokovi za ekstrakciju karakteristika
  - Uzorkovanje slojeva za vraćanje veličine slike
- **Korišćeni slojevi**
  - Conv2D, BatchNormalization, ReLU, MaxPooling2D, UpSampling2D
- **Prednosti**
  - Uči složene karakteristike i mapiranje boja
  - Bolja kolorizacija nego kod osnovnih autoenkodera
- **Ograničenja**
  - Nema preskočnih veza, tako da se neki prostorni detalji mogu izgubiti



# U-Net Model

- **Struktura**

- Napredni enkoder-dekoder sa preskočnim vezama
- Enkoder izdvaja karakteristike; dekoder rekonstruiše slike u boji
- Preskočne veze spajaju karakteristike enkodera i dekodera radi boljih detalja

- **Korišćeni slojevi**

- Conv2D, BatchNormalization, ReLU, MaxPooling2D, Dropout, UpSampling2D, concatenate

- **Prednosti**

- Čuva prostorne detalje i ivice
- Proizvodi najrealističnije i najdetaljnije boje

- **Ograničenja**

- Složeniji i zahteva više memorije i vremena za treniranje





# Proces treniranja

- **Trening set:** 7000 slika
- **Test set:** 1000 slika
- **Epohe:** 20 - 30 zavisno od modela
- **Veličina serije (*batch size*):** 64 - 128



# Evaluacija modela


- **Validacija:** Korišćen test set za praćenje učinka tokom obuke
- **Vizualizacija:** Prikazani crno-beli ulazi i predviđeni izlazi jedan pored drugog

# Primeri rezultata (Encoder-Decoder Model)


Grayscale Input



Original Color



Predicted Colorized




Grayscale Input



Original Color




Predicted Colorized



Grayscale Input



Original Color




Predicted Colorized




Grayscale Input



Original Color



Predicted Colorized



# Primeri rezultata (CNN Model)

Grayscale Input



Original Color



Predicted Colorized




Grayscale Input



Original Color




Predicted Colorized



Grayscale Input



Original Color




Predicted Colorized




Grayscale Input



Original Color



Predicted Colorized




# Primeri rezultata (U-Net Model)


Grayscale Input



Original Color



Predicted Colorized




Grayscale Input



Original Color




Predicted Colorized



Grayscale Input



Original Color




Predicted Colorized




Grayscale Input



Original Color



Predicted Colorized





# Poređenje arhitektura

- **Encoder-Decoder:** Brz, ali sa manje detalja
- **CNN:** Dobri rezultati, ali može da propustiti fine detalje
- **U-Net:** Najbolji rezultati, najbolje čuva detalje i boje



# Izazovi

- Veliko vreme obrade skupa podataka
- Tačnost boja (ponekad nerealne boje)
- *Overfitting* (rešeno ranim zaustavljanjem i ispuštanjem (*dropout*))



# Buduća poboljšanja

- Korišćenje Generativne Protivničke Mreže (GAN) za realističnije boje
- Korišćenje većeg i raznovrsnijeg skupa podataka
- Podaci veće rezolucije





# Zaključak

- Uspešno izgrađeni i obučeni modeli za kolorizaciju slika
- U-Net Model daje najbolje rezultate od svih korišćenih modela
- Naučili smo osnove o obradi slika, neuronskim mrežama i proceni modela



**KRAJ**